

BUSSINESS INTELLIGENCE

“Analisis Strategis Prediksi Penjualan Ritel Fashion Menggunakan *Recurrent Neural Network* (RNN): Optimalisasi Rantai Pasok dalam Konteks UNIQLO”



DOSEN PENGAMPU :

Muhammad Hafidh Firmansyah, S.Tr.Kom., M.Sc.

DISUSUN OLEH :

Nama	NIM	Golongan
Nabil Zivkolin Danendra	E31240615	B
M. Khoiril Nishrullah	E31241327	C
Ahmad Hilmy Febriandika	E31241905	C
Rafli Rama Dani	E31241943	D
Muhammad Rendi Kurniawan	E31240858	B

**PROGRAM STUDI MANAJEMEN INFORMATIKA
JURUSAN TEKNOLOGI INFORMASI
POLITEKNIK NEGERI JEMBER
2025**

DAFTAR ISI

I. Konteks Strategis: Keunggulan Ritel dalam Manajemen Permintaan (The UNIQLO Imperative)....	2
A. Urgensi Prediksi Penjualan dalam Model Bisnis Ritel Vertikal.....	2
B. Peran Sentralisasi Informasi dan Siklus Pengambilan Keputusan (TCM).....	2
C. Definisi Risiko Kuantitatif: Dampak Akurasi Prediksi terhadap Profitabilitas.....	3
II. Pengumpulan Data dan Preparasi untuk Analisis Temporal.....	4
A. Identifikasi dan Validasi Dataset Kaggle.....	4
B. Isu Kualitas Data dan Pra-pemrosesan Awal.....	4
C. Transformasi ke Format Temporal dan Agregasi Data.....	4
III. Rekayasa Fitur Lanjutan untuk Deep Learning Time Series.....	6
A. Konstruksi Fitur Lag dan Jendela Geser (Sliding Window).....	6
B. Ekstraksi Pola Musiman Ganda dan Regressor Eksternal.....	6
C. Strategi Pembagian Data untuk Validasi yang Kuat.....	7
IV. Pengembangan Model Recurrent Neural Network (RNN) untuk Peramalan.....	7
A. Justifikasi Arsitektur: Keunggulan LSTM dan GRU.....	7
B. Desain Arsitektur Multi-Lapisan dan Hyperparameter Tuning.....	8
V. Evaluasi Kinerja dan Perbandingan Model Neural Network.....	9
A. Metrik Evaluasi Kuantitatif.....	9
B. Hasil Komparasi dan Kinerja Model.....	10
VI. Implikasi Bisnis dan Interpretasi Model untuk Pengambilan Keputusan Strategis.....	10
A. Penerapan Explainable AI (XAI): SHAP dan LIME.....	10
B. Keterkaitan Akurasi Prediksi NN dengan Pengelolaan Buffer Stock dan Siklus Produksi.....	11
VII. Kesimpulan dan Agenda Riset Lanjutan.....	11
A. Kesimpulan Kunci dan Kontribusi Strategis.....	11
B. Agenda Riset Lanjutan.....	11

I. Konteks Strategis: Keunggulan Ritel dalam Manajemen Permintaan (The UNIQLO Imperative)

A. Urgensi Prediksi Penjualan dalam Model Bisnis Ritel Vertikal

UNIQLO beroperasi di bawah strategi *Cost Leadership*, yang menempatkan efisiensi operasional dan minimalisasi biaya sebagai prioritas utama.¹ Strategi ini didukung oleh model rantai pasok yang terintegrasi secara vertikal, di mana perusahaan memiliki kontrol langsung atas seluruh proses mulai dari produksi hingga distribusi. Kontrol terpusat ini memberikan keunggulan kompetitif, tetapi juga meningkatkan risiko kerugian finansial akibat kesalahan peramalan permintaan.

Kebutuhan akan peramalan presisi muncul dari praktik operasional inti. UNIQLO mengamankan biaya produksi yang lebih rendah melalui pembelian bahan baku dalam jumlah besar (*bulk purchasing*) dan kemitraan strategis dengan produsen tekstil.¹ Dalam sistem terintegrasi ini, peramalan yang tidak akurat dapat menyebabkan keputusan pembelian bahan baku yang masif, yang jika salah, menghasilkan inventaris berlebihan yang mahal. Sebaliknya, prediksi yang terlalu rendah akan mengakibatkan kerugian penjualan. Penelitian yang membandingkan metode peramalan menunjukkan bahwa *computational intelligence*, khususnya Recurrent Neural Network (RNN), dapat mencapai performa akurasi yang lebih baik dalam prediksi penjualan ritel harian dibandingkan metode statistika tradisional.²

B. Peran Sentralisasi Informasi dan Siklus Pengambilan Keputusan (TCM)

Efektivitas rantai pasok UNIQLO sangat bergantung pada manajemen inventaris terpusat dan sistem berbagi informasi yang canggih.³ Pengambilan keputusan kritis dilakukan dalam rapat bisnis TCM (Top Management Conference) mingguan. Di forum ini, manajemen menganalisis data penjualan harian dan membuat peramalan permintaan pasar untuk menentukan langkah operasional yang tepat, seperti pesanan tambahan, diskon, atau likuidasi stok.³

Kualitas output dari rapat TCM ini secara langsung terikat pada akurasi peramalan yang digunakan. Kesalahan kecil dalam memprediksi permintaan pada tingkat toko dapat diperbesar seiring pergerakan ke hulu rantai pasok (produsen bahan baku), sebuah fenomena yang dikenal sebagai *bullwhip effect*.³ Model *Deep Learning* yang kokoh dan stabil, dengan menyediakan prediksi permintaan yang terkalibrasi dan konsisten, berfungsi sebagai pertahanan terhadap *bullwhip effect*. Dengan mengurangi ketidakpastian permintaan hulu, model ini memastikan semua pemangku kepentingan dalam rantai pasok terintegrasi bekerja berdasarkan satu

sumber data yang dapat dipercaya, sehingga meningkatkan efisiensi operasional secara keseluruhan dan mengurangi risiko inventaris yang tidak perlu.

C. Definisi Risiko Kuantitatif: Dampak Akurasi Prediksi terhadap Profitabilitas

Metrik kinerja utama untuk menilai efisiensi rantai pasok adalah *Gross Profit Margin* (GPM), yang merupakan profit yang tersisa setelah mengurangi Harga Pokok Penjualan (HPP) dari Penjualan Bersih.⁴ GPM mencerminkan efisiensi operasional. Margin ini sangat bervariasi di industri; ritel umum memiliki GPM sekitar 24.27%, sementara *online retail* dapat mencapai 42.53%.⁵

Terdapat dua jenis kerugian finansial yang signifikan yang disebabkan oleh peramalan yang buruk:

1. **Kerugian Tipe I (*Overstock*):** Ketika prediksi penjualan terlalu tinggi, perusahaan menghadapi kelebihan inventaris. Hal ini meningkatkan *Inventory Holding Costs* dan memaksa manajemen untuk melakukan likuidasi atau diskon yang tidak terencana (*mark-down*).³ *Markdown* ini secara langsung menurunkan total Pendapatan Kotor, yang pada gilirannya mengurangi GPM.⁴
2. **Kerugian Tipe II (*Out-of-Stock*):** Ketika prediksi terlalu rendah, terjadi kehabisan stok, yang menyebabkan hilangnya peluang penjualan (*opportunity cost*) dan menurunkan kepuasan pelanggan, berpotensi mendorong mereka beralih ke pesaing.⁶

Oleh karena itu, terdapat korelasi kausal langsung: model prediksi yang menghasilkan *Root Mean Squared Error* (RMSE) rendah memungkinkan pengurangan *buffer stock* yang diperlukan. Pengurangan *buffer stock* ini mengurangi biaya inventaris, menurunkan HPP efektif, dan secara signifikan meningkatkan GPM. Peningkatan akurasi prediksi adalah langkah awal dalam kuantifikasi dan mitigasi risiko finansial ini.

II. Pengumpulan Data dan Preparasi untuk Analisis Temporal

A. Identifikasi dan Validasi Dataset Kaggle

Untuk mereplikasi studi kasus ritel fashion, dipilih dataset yang relevan, yaitu "Fashion Retail Sales Dataset" dari Kaggle.⁷ Dataset ini mencakup 3,400 catatan transaksi penjualan ritel, yang memuat detail penting seperti *Item Purchased*, *Purchase Amount (USD)*, *Date Purchase*, *Review Rating*, dan *Payment Method*.⁸ Dataset ini menyediakan atribut esensial untuk melatih model peramalan penjualan harian atau mingguan pada tingkat *Stock Keeping Unit* (SKU).

B. Isu Kualitas Data dan Pra-pemrosesan Awal

Analisis kualitas data menunjukkan adanya nilai hilang yang signifikan. Terdapat 650 nilai hilang pada kolom *Purchase Amount (USD)* dan 324 nilai hilang pada kolom *Review Rating*.⁸ Penanganan nilai hilang ini krusial:

1. **Variabel Target:** Karena *Purchase Amount (USD)* adalah variabel target utama untuk regresi (peramalan penjualan), nilai hilang pada kolom ini tidak dapat diimputasi secara sederhana. Strategi yang paling aman adalah menghapus catatan (record) yang tidak memiliki jumlah pembelian, atau menggunakan teknik imputasi yang kompleks (misalnya, imputasi berbasis kategori produk) jika jumlah data hilang sangat besar.
2. **Regressor Eksternal:** Kolom *Review Rating* (berskala 1 hingga 5) yang hilang dapat diimputasi dengan nilai median atau diwakili oleh kategori terpisah ('Tidak Ada Rating') untuk memastikannya dapat digunakan sebagai regressor eksternal dalam model.

C. Transformasi ke Format Temporal dan Agregasi Data

Model RNN dan LSTM dirancang untuk memproses deret waktu kontinu. Oleh karena itu, data transaksi *point-in-time* harus dikonversi. Data agregasi harian (*Total Sales*) adalah format yang paling ideal.⁹ Format ini memungkinkan model untuk menangkap pola musiman dan tren jangka pendek yang penting bagi keputusan inventaris harian.

Setelah agregasi, data deret waktu perlu menjalani normalisasi, biasanya menggunakan MinMax Scaling. Normalisasi data adalah langkah wajib untuk *Deep Learning* karena memastikan bahwa bobot koneksi Neural Network tidak didominasi oleh fitur yang memiliki skala numerik besar (seperti nilai penjualan yang besar). Hal

ini mempercepat konvergensi model selama pelatihan dan menghasilkan kinerja yang lebih stabil.

Kolom Data	Tipe Data	Relevansi Bisnis	Catatan Implementasi
Date	Timestamp	Indeks Waktu Utama	Digunakan untuk mengidentifikasi tren musiman.
Total Sales (USD)	Float	Variabel Target (Y)	Agregasi Penjualan Harian/SKU.
Item Category (Encoded)	Vektor/Integer	Fokus Model (SKU Penting)	Input untuk <i>Multivariate Forecasting</i> atau kategori.
Review Rating (Imputed)	Float	Sentimen Konsumen	Regressor Eksternal yang penting.
Day of Week, Month	Integer	Fitur Musiman Ganda	Diekstrak dari kolom Date.

Table 1. Struktur Dataset Penjualan Ritel fashion Teragregasi (Adaptasi Kaggle)

III. Rekayasa Fitur Lanjutan untuk Deep Learning Time Series

Untuk peramalan deret waktu yang akurat, model *Deep Learning* harus diberi fitur yang secara eksplisit menggambarkan dependensi temporal.

A. Konstruksi Fitur Lag dan Jendela Geser (*Sliding Window*)

Algoritma RNN/LSTM secara intrinsik memerlukan data yang diformat sebagai urutan waktu. Teknik *sliding window* digunakan untuk mengubah dataset deret waktu menjadi pasangan input-output berurutan, di mana input terdiri dari nilai masa lalu (fitur *lag*), dan output adalah nilai masa depan yang diprediksi.

Pembuatan fitur *lag* penjualan (misalnya, penjualan \$H-1\$, \$H-7\$, \$H-14\$, dan \$H-30\$) sangat penting. Lag \$H-7\$ dan \$H-14\$ secara khusus menangkap pola pembelian mingguan dan dua mingguan. Dalam ritel, pola ini menyoroti kenaikan penjualan yang konsisten pada akhir pekan atau siklus promosi mingguan.¹⁰ Lag jangka panjang, seperti \$H-30\$, memungkinkan model untuk mengidentifikasi siklus bulanan, yang seringkali terkait dengan tanggal gaji atau siklus inventaris yang lebih luas.

B. Ekstraksi Pola Musiman Ganda dan Regressor Eksternal

Bisnis ritel fashion ditandai oleh *multiple seasonal patterns* yang beroperasi pada skala waktu yang berbeda (harian, mingguan, tahunan).¹⁰ *Feature engineering* harus secara eksplisit mengekstrak pola ini.

1. **Fitur Kalender:** Fitur kategorikal seperti Hari dalam Seminggu, Bulan, dan Hari Libur Nasional (*Holiday Flags*) harus dibuat. Hari Libur adalah *regressor eksternal* yang dikenal memiliki dampak kuat pada total pendapatan harian.⁹
2. **Integrasi Regressor Eksternal:** Data non-temporal yang mempengaruhi permintaan harus diintegrasikan. Selain fitur kalender, rata-rata Review Rating harian⁸ dapat berfungsi sebagai proxy untuk sentimen dan kepuasan konsumen. Dalam konteks UNIQLO, regressor ini sangat penting karena sejalan dengan misi perusahaan untuk terus mengevaluasi produk dan kenyataan yang ada di rantai penjualan.¹¹

C. Strategi Pembagian Data untuk Validasi yang Kuat

Dalam *time series forecasting*, metode pembagian data tradisional (*random split*) tidak dapat digunakan. Pembagian harus dilakukan secara *time-based*, memastikan bahwa data pengujian selalu merupakan periode waktu yang *lebih baru* daripada data pelatihan. Ini mensimulasikan skenario prediksi di dunia nyata.¹²

Proporsi yang umum digunakan adalah membagi data menjadi 80% observasi awal untuk pelatihan dan validasi, dan 20% sisanya untuk pengujian.⁹ Selanjutnya, untuk memastikan *hyperparameter tuning* yang optimal dan konsisten, disarankan menggunakan teknik *walk-forward validation* daripada *k-fold cross-validation* standard. *Walk-forward validation* secara iteratif melatih model pada data historis dan menguji pada periode waktu segera setelahnya, memberikan evaluasi yang lebih realistis tentang kemampuan model untuk melakukan generalisasi di masa depan.¹³

IV. Pengembangan Model *Recurrent Neural Network* (RNN) untuk Peramalan

A. Justifikasi Arsitektur: Keunggulan LSTM dan GRU

Model RNN tradisional menghadapi tantangan serius yang dikenal sebagai *vanishing gradient*, yang menghambat kemampuan mereka untuk mempelajari dan mempertahankan dependensi data jangka panjang. Dalam ritel, dependensi jangka panjang—seperti tren musiman tahunan atau keberhasilan produk tertentu yang bertahan lama—sangat penting.

Untuk mengatasi ini, digunakan varian RNN:

1. **Long Short-Term Memory (LSTM):** Arsitektur ini dirancang untuk mempertahankan informasi dalam periode waktu yang lama melalui penggunaan *memory cells* yang dikontrol oleh *gates* (input, forget, output).¹⁴
2. **Gated Recurrent Unit (GRU):** GRU adalah varian LSTM yang lebih sederhana, menggabungkan *forget* dan *input gates* menjadi *update gate*, menghasilkan model dengan lebih sedikit parameter. Studi peramalan deret waktu, termasuk yang berkaitan dengan peramalan harga pasar, sering menunjukkan bahwa GRU memberikan hasil keseluruhan terbaik, terutama untuk peramalan *multivariate*.¹⁴ Dengan efisiensi komputasi yang lebih tinggi dan akurasi yang kompetitif, GRU adalah kandidat kuat untuk menjadi model *champion* dalam prediksi penjualan ritel harian.

B. Desain Arsitektur Multi-Lapisan dan *Hyperparameter Tuning*

Arsitektur yang direkomendasikan adalah *Stacked RNN*, yang umumnya terdiri dari dua lapisan berturut-turut. Desain ini memungkinkan ekstraksi fitur temporal hierarkis.

- **Lapisan Input:** Menerima urutan data (fitur *lag*, fitur kalender, dan regressor eksternal) yang telah dinormalisasi.
- **Lapisan Tersembunyi (LSTM/GRU):** Dua lapisan, misalnya 64 unit diikuti oleh 32 unit, memproses dependensi temporal.
- **Lapisan Output:** Lapisan Dense (fully connected) dengan satu neuron dan fungsi aktivasi Linear, karena tugas ini adalah regresi (memprediksi nilai numerik penjualan).

Optimalisasi model memerlukan *hyperparameter tuning* yang sistematis.¹³ Parameter kunci yang harus diuji meliputi:

- **Panjang Time Steps:** Menguji panjang urutan input (misalnya, 7, 12, dan 30) untuk menentukan horizon waktu optimal yang paling akurat menangkap pola ritel.
- **Batch Size:** Menguji ukuran *batch* 16, 32, dan 64.¹³
- **Learning Rate:** Menggunakan *optimizer* seperti Adam, dengan laju belajar yang diuji (misalnya, 0.001) untuk memastikan konvergensi yang cepat tanpa *overshooting*.
- **Regularisasi:** Lapisan Dropout (misalnya, 20%) harus diterapkan di antara lapisan RNN untuk mencegah *overfitting*, terutama pada dataset dengan musiman yang kompleks.

Komponen Arsitektur	Parameter/Nilai yang Dituning	Rasionalisasi Teknis
Arsitektur Utama	LSTM / GRU	Membandingkan akurasi dan efisiensi untuk dependensi temporal non-linear. ¹⁴
Panjang Sekuens (Time Steps)	7, 12, atau 30	Optimalisasi untuk menangkap pola musiman mingguan dan bulanan. ¹³

Lapisan RNN	2 Lapisan (64, 32 unit)	Memungkinkan ekstraksi fitur hierarkis sambil memitigasi <i>vanishing gradient</i> .
Optimizer	Adam	Standar industri untuk konvergensi pelatihan yang efisien.
Metrik Kerugian (Loss Metric)	MSE (Mean Squared Error)	Menerapkan penalti yang lebih besar pada kesalahan prediksi yang ekstrem, yang memiliki dampak finansial tinggi.

Table 2. Konfigurasi Arsitektur Deep Learning (LSTM/GRU) untuk Prediksi Penjualan

V. Evaluasi Kinerja dan Perbandingan Model Neural Network

A. Metrik Evaluasi Kuantitatif

Kinerja model regresi harus diukur dengan metrik yang dapat diterjemahkan ke dalam konteks risiko bisnis:

1. **Root Mean Squared Error (RMSE):** Metrik utama. RMSE sangat berguna karena memiliki satuan yang sama dengan variabel target (misalnya, USD), memudahkan komunikasi. RMSE memberikan bobot yang lebih besar pada kesalahan prediksi yang besar, yang dalam bisnis ritel berarti kerugian finansial yang signifikan (misalnya, kesalahan prediksi pada SKU dengan penjualan volume tinggi).
2. **Mean Absolute Error (MAE):** Memberikan ukuran linear kesalahan rata-rata, yang lebih mudah diinterpretasikan sebagai penyimpangan rata-rata harian yang diharapkan.
3. **Mean Absolute Percentage Error (MAPE):** Penting untuk mengevaluasi seberapa besar kesalahan relatif terhadap nilai aktual penjualan. Metrik ini memberikan perspektif tentang akurasi yang standar, terlepas dari skala penjualan.

B. Hasil Komparasi dan Kinerja Model

Perbandingan antara LSTM dan GRU akan menentukan model *champion*. Literatur menunjukkan bahwa dalam prediksi penjualan ritel, RNN dapat mencapai akurasi hingga 58%.¹⁵ Meskipun LSTM unggul dalam dependensi yang sangat panjang, GRU sering dipilih karena kombinasi akurasi yang kompetitif dan kecepatan pelatihan yang lebih tinggi.¹⁴

Yang terpenting, hasil kuantitatif ini harus diubah menjadi risiko finansial yang dapat ditoleransi. Jika *Mean Absolute Error* model adalah \$X USD, ini berarti model salah rata-rata \$X per hari. Dengan GPM rata-rata industri ritel⁵, manajemen dapat menghitung secara pasti seberapa besar penghematan biaya inventaris (misalnya, pengurangan biaya likuidasi atau HPP) yang dapat dicapai dengan pengurangan RMSE sebesar \$Y\$. Kuantifikasi ini membenarkan investasi sumber daya dalam implementasi arsitektur *Deep Learning* yang kompleks.

VI. Implikasi Bisnis dan Interpretasi Model untuk Pengambilan Keputusan Strategis

A. Penerapan *Explainable AI* (XAI): SHAP dan LIME

Salah satu tantangan terbesar dalam penerapan *Deep Learning* di lingkungan korporat adalah sifat *black-box* model. Dalam siklus pengambilan keputusan yang cepat seperti rapat TCM mingguan UNIQLO³, manajemen tidak hanya perlu tahu *apa* yang akan terjadi, tetapi juga *mengapa* prediksi itu dibuat.¹⁶ Penerapan *Explainable AI* (XAI) sangat penting untuk membangun kepercayaan.

Dua metode XAI utama untuk deret waktu adalah:

1. **SHAP (*SHapley Additive exPlanations*)**: Memberikan interpretasi global dengan mengidentifikasi fitur mana yang paling penting secara keseluruhan (misalnya, *Lag H-7*, *Holiday Flags*, atau *Review Rating*) dalam mendorong penjualan.¹⁶
2. **LIME (*Local Interpretable Model-agnostic Explanations*)**: Memberikan penjelasan lokal untuk prediksi individu. Ini sangat berguna ketika model memprediksi penyimpangan atau lonjakan penjualan yang tidak terduga, yang memerlukan investigasi cepat oleh manajemen.¹⁷

Penggunaan XAI memperbolehkan validasi hipotesis bisnis. Misalnya, jika manajemen berasumsi bahwa faktor promosi adalah pendorong utama penjualan saat ini, tetapi analisis SHAP menunjukkan fitur seperti *Review Rating* atau Hari Libur memiliki nilai Shapley yang jauh lebih tinggi, fokus strategis perusahaan dapat dialihkan. Hal ini mendorong manajemen untuk bertindak bukan hanya berdasarkan respons stok, tetapi juga pada sentimen pasar dan kualitas produk, sejalan dengan misi Fast Retailing yang selalu menganalisis kenyataan di rantai penjualan.¹¹

B. Keterkaitan Akurasi Prediksi NN dengan Pengelolaan *Buffer Stock* dan Siklus Produksi

Akurasi prediksi yang lebih tinggi secara fundamental mengurangi ketidakpastian permintaan di pasar.⁶ Dalam manajemen inventaris, ketidakpastian permintaan adalah pendorong utama kebutuhan akan *buffer stock* atau *safety stock*—inventaris tambahan yang disimpan untuk menghindari *out-of-stock*.

Dengan menggunakan model GRU yang terbukti memberikan akurasi tinggi, perusahaan dapat secara aman mengurangi tingkat *buffer stock* yang mahal. Pengurangan ini secara langsung menurunkan biaya modal yang terikat dalam inventaris. Selain itu, peramalan yang solid untuk horizon 30 hingga 60 hari memungkinkan penentuan waktu *planned promotions*³ yang optimal, memaksimalkan GPM, dan menghindari kebutuhan akan diskon panik yang tidak efisien, sejalan dengan tujuan manajemen inventaris yang efektif.⁶

VII. Kesimpulan dan Agenda Riset Lanjutan

A. Kesimpulan Kunci dan Kontribusi Strategis

Implementasi model *Deep Learning* berbasis GRU/LSTM dalam studi kasus ritel fashion ini memberikan dasar peramalan yang kuat, yang mampu menangkap pola musiman ganda dan dependensi non-linear yang kompleks, jauh melampaui kemampuan model tradisional. Dalam konteks operasional UNIQLO, peningkatan presisi peramalan ini secara langsung mendukung strategi *Cost Leadership* dengan meminimalkan risiko *overstock* dan *mark-down*, sehingga melindungi *Gross Profit Margin*.

Kontribusi strategis terpenting adalah integrasi XAI. Dengan menerapkan SHAP dan LIME, model *Deep Learning* diubah dari *black-box* menjadi alat penunjang keputusan yang transparan. XAI memungkinkan para eksekutif untuk memahami pendorong penjualan aktual dan menyesuaikan keputusan taktis (misalnya, di rapat TCM) berdasarkan bukti faktual dari model, mengoptimalkan pengelolaan inventaris dan siklus hidup produk.

B. Agenda Riset Lanjutan

Untuk menyempurnakan kapabilitas prediktif ini ke tingkat yang lebih tinggi, direkomendasikan tiga area riset lanjutan:

1. **Penyempurnaan Model *Multivariate Time Series* (MTS) Forecasting:** Studi kasus saat ini berfokus pada peramalan *univariate* (satu deret waktu). Langkah selanjutnya adalah menerapkan MTS, di mana penjualan satu produk (misalnya, celana panjang) digunakan sebagai fitur untuk memprediksi penjualan produk lain yang terkait secara komplementer (misalnya, kemeja). Pendekatan ini memanfaatkan korelasi antar-seri, yang terbukti meningkatkan akurasi dalam kasus deret waktu yang saling terkait.¹⁰
2. **Optimasi *Deep Learning* Klasifikasi Laba/Rugi:** Selain peramalan regresi, model *Multi-Layer Perceptron* (MLP) dapat dieksplorasi untuk klasifikasi risiko profitabilitas.¹⁹ MLP adalah arsitektur *feedforward* yang ideal untuk tugas klasifikasi.²⁰ Sebuah studi terkait menunjukkan bahwa arsitektur Backpropagation MLP (misalnya 4-50-1) dapat mencapai akurasi pengujian sebesar 80% dalam prediksi laba rugi.²¹ Model ini dapat diterapkan untuk mengklasifikasikan SKU baru atau yang akan datang ke dalam kategori 'Untung' (GPM di atas ambang batas) atau 'Rugi' (GPM di bawah ambang batas), memberikan sistem peringatan dini kepada manajemen produk.
3. **Integrasi *Real-Time* dan *Streaming Data*:** Mengembangkan model *forecasting* untuk digunakan pada data *streaming* (misalnya, data *clickstream* dari e-commerce) akan memungkinkan perusahaan untuk menghasilkan prediksi ultra-pendek, memungkinkan respons harga dan inventaris yang dinamis secara *real-time* untuk memaksimalkan peluang penjualan mendadak.

DAFTAR PUSTAKA

1. Uniqlo Pricing Strategy: Balancing Quality and Affordability - NewswireJet, accessed November 21, 2025, <https://newswirejet.com/uniqlo-pricing-strategy/>
2. Multivariate TIME Series Forecasting Pada Penjualan Barang Retail Dengan Recurrent Neural Network - Neliti, accessed November 21, 2025, <https://www.neliti.com/publications/466725/multivariate-time-series-forecasting-pada-penjualan-barang-retail-dengan-recurre>
3. Study on Supply Chain Management of UNIQLO - Atlantis Press, accessed November 21, 2025, <https://www.atlantis-press.com/article/25887559.pdf>
4. Gross Profit Margin: Formula and What It Tells You - Investopedia, accessed November 21, 2025, https://www.investopedia.com/terms/g/gross_profit_margin.asp
5. Pengertian Gross Profit Margin, Cara Hitung & Cara Meningkatkan - Kledo, accessed November 21, 2025, <https://kledo.com/blog/gross-profit-margin/>
6. Manajemen Inventaris Ritel yang Efektif - ABJ Cloud Solutions, accessed November 21, 2025, <https://abjcloudsolutions.com/id/manajemen-inventaris-ritel-yang-efektif/>
7. Fashion Retail Sales Dataset - Kaggle, accessed November 21, 2025, <https://www.kaggle.com/datasets/fekihmea/fashion-retail-sales/data>
8. Fashion Retail Sales Dataset - Kaggle, accessed November 21, 2025, <https://www.kaggle.com/datasets/atharvasoundankar/fashion-retail-sales>
9. Analisis Tren dan Prediksi Penjualan Restoran Menggunakan Model Time Series Prophet - Jurnal Universitas Mulia, accessed November 21, 2025, <https://journal.universitasmulia.ac.id/index.php/metik/article/download/1101/539>
10. LSTM-MSNet: Leveraging Forecasts on Sets of Related Time Series with Multiple Seasonal Patterns(Paper Summary and Implementation) - Ritul, accessed November 21, 2025, <https://ritul-patidar.medium.com/lstm-msnet-leveraging-forecasts-on-sets-of-related-time-series-with-multiple-seasonal-patterns-f9c920ac64d8>
11. Fast Retailing Way, accessed November 21, 2025, https://www.fastretailing.com/eng/about/frway/pdf/ERWAY_Indonesian.pdf
12. Membagi set data asli | Machine Learning - Google for Developers, accessed November 21, 2025, <https://developers.google.com/machine-learning/crash-course/overfitting/dividing-datasets?hl=id>
13. Nabil Izzany1, Mohammad Masjkur1‡, Akbar Rizki1, accessed November 21, 2025, <https://journal-stats.ipb.ac.id/index.php/ijsa/article/download/1247/465/4643>
14. Neural Networks for Financial Time Series Forecasting - MDPI, accessed November 21, 2025, <https://www.mdpi.com/1099-4300/24/5/657>
15. Perbandingan algoritma LSTM & RNN untuk prediksi harga pasar saham pada keuangan syariah - Digital Library UIN Sunan Gunung Djati Bandung, accessed November 21, 2025, <https://digilib.uinsgd.ac.id/102089/>
16. [2508.12253] Interpreting Time Series Forecasts with LIME and SHAP: A Case Study on the Air Passengers Dataset - arXiv, accessed November 21, 2025, <https://arxiv.org/abs/2508.12253>
17. (PDF) Explainable Deep Learning for Time Series Analysis: Integrating SHAP and LIME in LSTM-Based Models - ResearchGate, accessed November 21, 2025, https://www.researchgate.net/publication/389675947_Explainable_Deep_Learning_for_Ti

- [me_Series_Analysis_Integrating_SHAP_and_LIME_in_LSTM-Based_Models](#)
18. (PDF) Multivariate Time Series Forecasting pada Penjualan Barang Retail dengan Recurrent Neural Network - ResearchGate, accessed November 21, 2025, https://www.researchgate.net/publication/367505423_Multivariate_Time_Series_Forecasting_pada_Penjualan_Barang_Retail_dengan_Recurrent_Neural_Network
 19. Kajian Literatur Multi Layer Perceptron Seberapa Baik Performa, accessed November 21, 2025, https://www.researchgate.net/publication/385598266_Kajian_Literatur_Multi_Layer_Perceptron_Seberapa_Baik_Performa_Algoritma_Ini
 20. What are the differences between MLP and DNN? | Kaggle, accessed November 21, 2025, <https://www.kaggle.com/discussions/questions-and-answers/309667>
 21. MODEL ARSITEKTUR NEURAL NETWORK DENGAN BACKPROPOGATION PADA PREDIKSI TOTAL LABA RUGI KOMPREHENSIF BANK UMUM KONVENTIONAL | Windarto | KLIK, accessed November 21, 2025, <https://klik.ulm.ac.id/index.php/klik/article/view/148/0>